



SAMSUNG



Nethone

**VERTICA** 

# NLP w języku polskim - obecny stan wiedzy

Łukasz Kobyliński, Sages / IPI PAN @lkobylinski

# Pare słów o mnie

### Łukasz (@lkobylinski)

- Research @ IPI PAN (ICS PAS)
- Consulting @ SigDelta
- Management @ Sages
- Founder @ Labellery









**Warsaw University** of Technology



# O czym chciałbym powiedzieć?

- NLP to nośny temat, ale najczęściej w kontekście języka angielskiego.
- Jak wygląda sytuacja przetwarzania języka naturalnego w kontekście języka polskiego?
- Czy warto się tym zajmować i jakie są **otwarte problemy**?

## Wiemy, że NLP jest istotne

Zastosowania bezpośrednio w biznesie

- speech recognition
- question answering
- sentiment analysis
- coreference resolution
- information extraction
- event identification
- named entity recognition
- sense disambiguation





koordynowałem projekt rebrandingu oraz wdrożenia nowej identyfikacji wizualnej. Chce rozwijać moje kluczowe umiejetności jak



- Nadzoruje publikacje treści na stronach internetowych firmy

2003.03 - Firma ABC - Specialista ds. Marketingu

2012.10 Zakres obowiazków:

- · Akceptowałem druk materiałów marketingowych
- Prowadziłem firmowe media społecznościowe

2003 01 - Firma ABC - Praktykant w działe marketing

. Tworzyłem teksty marketingowe do ulotek produktowych

 Analizowałem oferty konkurencii Dzieki pozytywnej ocenie praktyk otrzymałem możliwość pracy etatowej ora

# A jak to wygląda dla języka polskiego?

Wciąż niewiele praktycznych implementacji bardziej zaawansowanych metod.

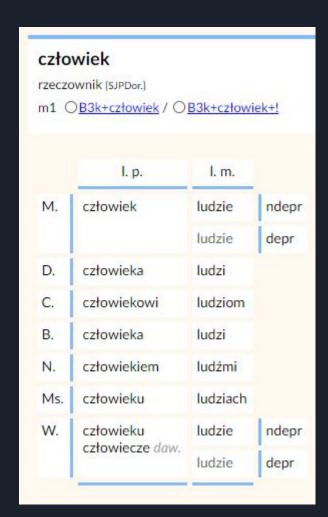
### Typowe powody:

- język polski jest obiektywnie trudniejszy w przetwarzaniu,
- brak gotowych narzędzi i łatwych w użyciu bibliotek,
- niewystarczające zasoby językowe.

# Dlaczego NLP dla polskiego jest trudne? (#1)

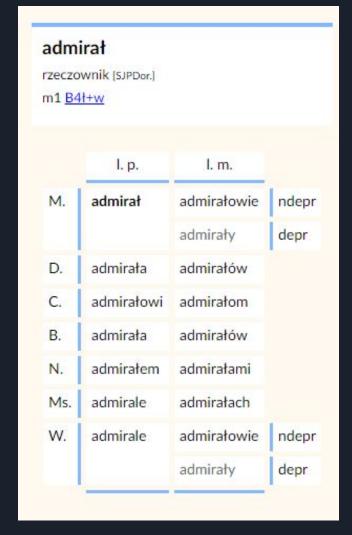
### Polski jest językiem fleksyjnym

- Liczba możliwych form w korpusie jest dużo większa, niż np. dla języka angielskiego,
- wiele form jest morfologicznie niejednoznacznych
  - o człowieka (D. dopełniacz / B. biernik)
  - o człowieku (Ms. miejscownik / W. wołacz)
  - ludzie (M. mianownik / W. pl. wołacz l. mn.)
  - ludzi (D. dopełniacz / B. pl. biernik l. mn.)



# Dlaczego NLP dla polskiego jest trudne? (#2)

Homonimia





# Dlaczego NLP dla polskiego jest trudne? (#3)

### Swobodny szyk zdania

- Język angielski
  - John loves Mary (SVO)
- Język polski
  - Jan kocha Marię (SVO),
  - Jan Marię kocha,
  - Marię kocha Jan,
  - Marię Jan kocha,
  - o Kocha Marię Jan,
  - Kocha Jan Marię.

Dlaczego NLP dla polskiego jest trudne? (#4)

W konsekwencji: opis języka jest dużo bardziej złożony

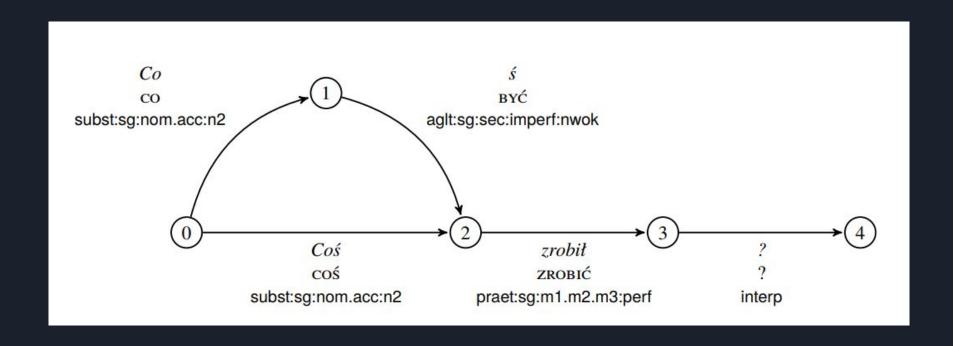
Na przykład: znakowanie morfosyntaktyczne

- j. angielski: 36 200 tagów, np. Penn Treebank:
  - NN noun (singular); NNS noun (plural);
  - VB verb, base form; VBD verb, past tense
- j. polski: 4 000 teoretycznie możliwych tagów! (podobnie dla czeskiego, ok. 2 000 w jęz. słoweńskim).

Number	Tag	Description
1.	CC	Coordinating conjunction
2.	CD	Cardinal number
3.	DT	Determiner
	EX	Existential there
5.	FW	Foreign word
6.	IN	Preposition or subordinating conjunction
7.	JJ	Adjective
8.	JJR	Adjective, comparative
9.	JJS	Adjective, superlative
10.	LS	List item marker
11.	MD	Modal
12.	NN	Noun, singular or mass
		Noun, plural
14.	NNP	Proper noun, singular
15.		Proper noun, plural
16.	PDT	Predeterminer
17.		Possessive ending
18.		Personal pronoun
19.	PRP\$	Possessive pronoun
20.	RB	Adverb
21.	RBR	Adverb, comparative
	RBS	Adverb, superlative
		Particle
24.	SYM	Symbol
25.	TO	to
26.	UH	Interjection
27.	VB	Verb, base form
28.		Verb, past tense
29.	VBG	Verb, gerund or present participle
30.	VBN	Verb, past participle
31.	VBP	Verb, non-3rd person singular present
32.	VBZ	Verb, 3rd person singular present
33.	WDT	Wh-determiner
34.	WP	Wh-pronoun
35.		Possessive wh-pronoun
36.	WRB	Wh-adverb

# Dlaczego NLP dla polskiego jest trudne? (#5)

Bonus: niejednoznaczności segmentacyjne



# NLP w języku polskim - czy jest dobrze?

### Co umiemy robić z wysoką dokładnością?

Zadanie	Polski	Angielski
Lematyzacja	(Waszczuk '12) <b>~96%</b>	
Znakowanie morfosyntaktyczne	(Krasnowska '17) <b>94,5%</b>	(Choi '2016) <b>97,64%</b>
Parsowanie zależnościowe	(Wróblewska '17) <b>84-93%</b>	(Dozat & Manning '17) <b>95,75</b> %
Rozpoznawanie nazw własnych	(Marcińczuk et al. '13) <b>80-85%</b> (F1)	(Strubell et al. '17) <b>86,81</b> % (F1)

## NLP w języku polskim - czy jest dobrze?

### Jakie inne główne zadania były podejmowane?

- ujednoznacznianie sensu słów,
- analiza wydźwięku,
- analiza koreferencji,
- tworzenie podsumowań,
- rozpoznawanie sytuacji,

### Wyzwania:

- generowanie języka naturalnego,
- transfer learning.

# Znakowanie morfosyntaktyczne (tagowanie)

### Dotychczasowe podejścia:

- 2007: znakowanie oparte na regułach (TaKiPI), ok. 88% dokładności,
- **2010**: tager Brilla dostosowany do j. polskiego (PANTERA), ok. 89% dokładności,
- 2012: uczenie pamięciowe (WMBT), ok. 90% dokładności,
- **2012**: warunkowe pola losowe (WCRFT, Concraft), ok. 91% dokładności,
- 2014: łączenie klasyfikatorów (PoliTa), ok. 92% dokładności.

# Czy istniejące metody można poprawić?

#### PolEval 2017

- konkurs wzorowany na Kaggle,
- obecnie związany z zadaniami z obszaru NLP dla j. polskiego.

### W 2017 roku otrzymaliśmy:

- 16 zgłoszeń od 9 zespołów,
- wszystkie zgłoszenia (!) oparte były na sieciach neuronowych.

### POLEVAL 2017 Home Tasks Dates Submission Results Prizes Publication Organizers



#### Task 1: POS Tagging

#### Introduction

There is an ongoing discussion whether the problem of part of speech tagging is already solved, at least for English (see Manning 2011), by reaching the tagging error rates similar or lower than the human inter-annotator agreement, which is ca. 97%. In the case of languages with rich morphology, such as Polish, there is however no doubt that the accuracies of around 91% delivered by taggers leave much to be desired and more work is needed to proclaim this task as solved.

The aim of this proposed task is therefore to stimulate research in potentially new approaches to the problem of POS tagging of Polish, which will allow to close the gap between the tagging accuracy of systems available for English and languages with rich morphology.

#### Task definition

#### Subtask (A): Morphosyntactic disambiguation and guessing

Given a sequence of segments, each with a set of possible morphosyntactic interpretations, the goal of the task is to select the correct interpretation for each of the segments and provide an interpretation for segments for which only 'ign' interpretation has been given (segments unknown to the morphosyntactic dictionary).

#### Subtask (B): Lemmatisation

Given a sequence of segments, each with a set of possible morphosyntactic interpretations, the goal of the task is to select the correct lemma for each of the segments and provide a lemma for segments for which only 'ign' interpretation has been given (segments unknown to the morphosyntactic dictionary).

# Znakowanie morfosyntaktyczne po PolEval 2017

		deep	hand-crafted	character-level	word-level
System name	Acc (%)	network	features	embeddings	embeddings
Toygger	94.6343	yes	yes	no	yes
$KRNNT\_AB$	93.8083	yes	yes	no	no
NeuroParser	93.6109	yes	no	yes	no
AvgPer_Forced	90.9134	no	yes	no	no
Concraft	91.6115	no	yes	no	no
WCRFT	91.1693	no	yes	no	no
WMBT	90.6722	no	yes	no	no

### PolEval 2018

### Tegoroczna edycja PolEval

- Task 1: Parsowanie zależnościowe.
- Task 2: Rozpoznawanie jednostek nazewnicznych (NER).
- Task 3: Modele językowe.

# Czy są biblioteki, z których można skorzystać?

Niestety, w większości bez wsparcia dla języka polskiego:

- NLTK dobra do badań naukowych i edukacji,
- Spacy.io dobra na produkcji zalążek wsparcia dla j. polskiego.

### Pozostałe:

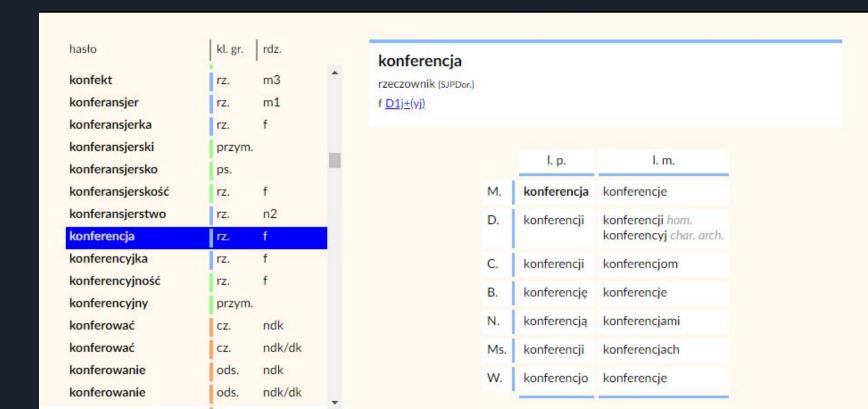
- CoreNLP, OpenNLP możliwość trenowania własnych modeli,
- gensim wykorzystanie reprezentacji wektorowych słów (zanurzenia).

### Korpusy tekstowe z dostępnym źródłem

Korpus	Rozmiar (segmentów)	Anotacja	
Narodowy Korpus Języka Polskiego	~1,2 mln	Ręczna: POS, NER, WSD, frazy składniowe	
KPWr	~ 450 tys.	Automatyczna: POS, NER, WSD, frazy składniowe, sytuacje	
Polski Korpus Sejmowy	~ 300 mln	Automatyczna: POS, NER, frazy składniowe	
Korpus Polskiej Wikipedii	~ 169 mln	Automatyczna: POS, NER, frazy składniowe	
PolEval 2018	> 400 mln	brak	

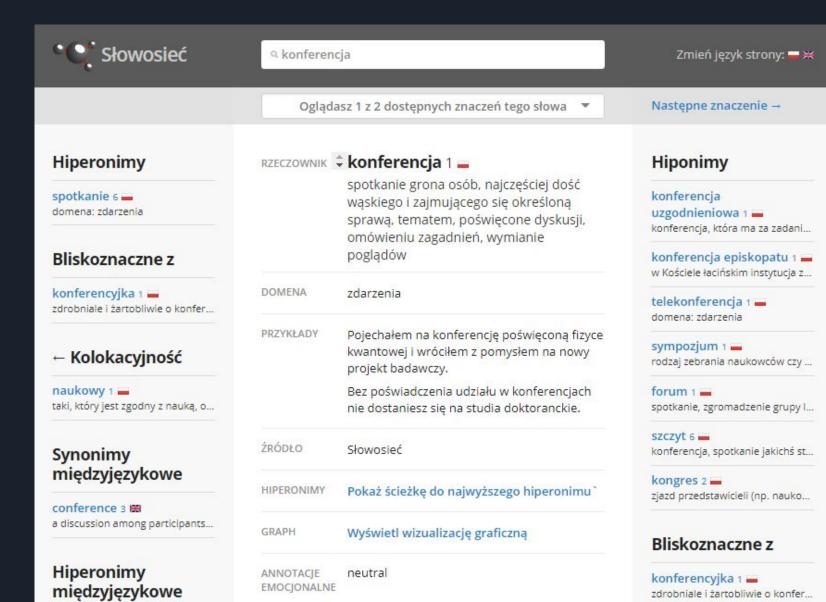
### Słownik morfologiczny (sgjp.pl)

- SGJP tabele odmian gramatycznych słów w j. Polskim
- Morfeusz narzędzie, pozwalające na efektywne przeszukiwanie



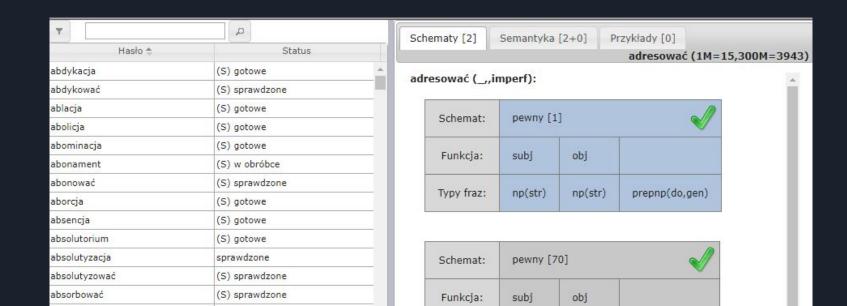
### Słowosieć

- Web
- API
- XML

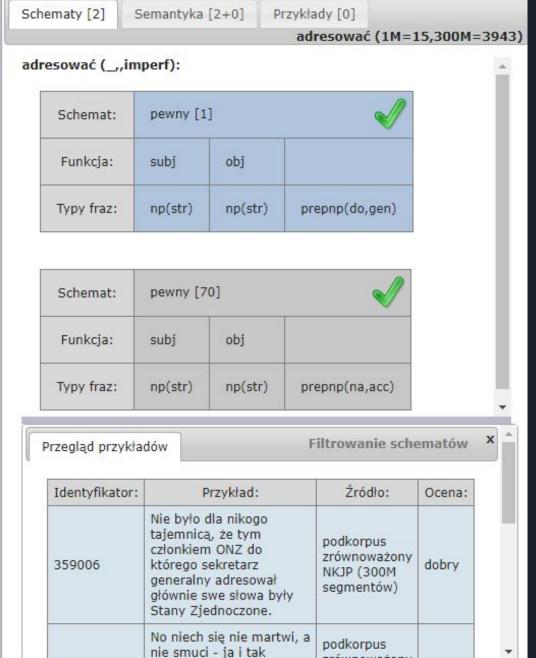


### Słownik walencyjny

opisuje sposób, w jaki określone jednostki językowe wiążą się ze swoimi podrzędnikami

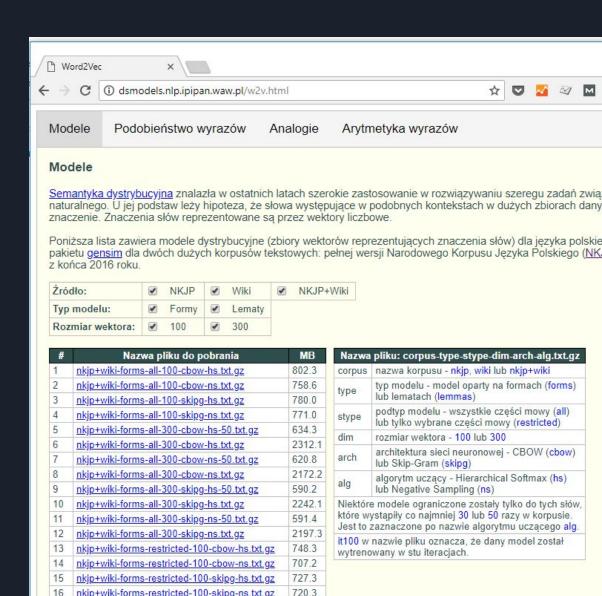






Zanurzenia słów (embeddings)

http://dsmodels.nlp.ipipan.waw.pl



# NLP w języku polskim - nie tylko publikacje naukowe

Home page

CLARIN-PL - narzędzia

(http://clarin-pl.eu/en/uslugi/)



Services

**Media library** 



**About project** 

#### Chunker

program do płytkiej analizy składniowej

Zobacz demo



#### Websty

interfejs webowy do grupowania tekstów w jezyku polskim

Przejdź do Websty ▶



Licenses

#### Nowy Morfeusz

analizator morfologiczny umożliwiający dostosowanie do

Przejdź do Nowego Morfeusza >



#### Liner2

rozpoznawanie jednostek identyfikacyjnych i wyrażeń temporalnych

Przejdź do Liner2 ▶



#### Inforex

system do edycji anotowanych korpusów

Zobacz Inforex ▶



#### klasyfikator tematyczny tekstów WiKNN

pierwsza wersja klasyfikatora tematycznego Wikipedia K-Nearest Neighbours dla tekstów polskich i angielskich

Przejdź do klasyfikatora >



#### Kuźnia

narzędzie do (współ)tworzenia fleksyjnych słowników dziedzinowych

Przejdź do Kuźni ▶



#### WNLoom-Viewer

aplikacja do przeglądania Słowosieci

Pobierz WNLoom-Viewer ▶



#### Mapa Literacka

rozpoznawanie odniesień do nazw geograficznych i miejscowych

Przejdź do Mapy Literackiej >



#### MeWeX

aplikacja do wydobywania z korpusu słowników kolokacji oraz tworzenia słowników jednostek leksykalnych

Przejdź do MeWeX ▶



#### Mowa

narzędzia i usługi do przetwarzania mowy

Zobacz narzędzia ▶



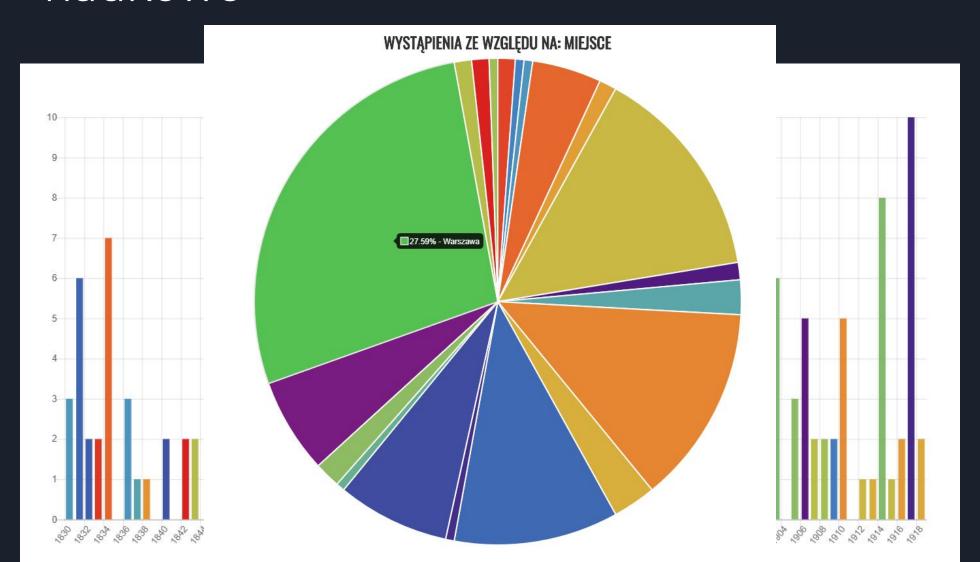
#### Transkrypcja fonetyczna

narzędzie do konwersji zapisu ortograficznego na fonetyczny

Przejdź do transkrypcji fonetycznej

٠

# NLP w języku polskim - nie tylko publikacje naukowe



# NLP w języku polskim - nie tylko publikacje naukowe

### **Jasnopis**



#### DANE

#### Tekst po analizie

W poniedziałek, 4 czerwca w Urzędzie Komisji Nadzoru Finansowego odbyło się pierwsze spotkanie Grupy roboczej ds. Blockchain. W jego skład weszli członkowie <u>międzyresortowego</u> Zespołu roboczego ds. rozwoju <u>innowacji</u> finansowych (FinTech) oraz dodatkowe podmioty rynkowe reprezentujące branżę <u>kryptowalut</u> i technologii Blockchain. Celem działania Grupy jest rozpoczęcie przez UKNF dialogu z przedstawicielami rynku na temat technologii DLT/Blockchain, w tym walut wirtualnych (tzw. <u>kryptowalut</u>) oraz innych tokenów cyfrowych, w kontekście właściwych uregulowań prawnych w tym zakresie, w tym przygotowanie Raportu końcowego z prac Grupy określającego stanowisko UKNF w przedmiotowym zakresie.

Grupa będzie zajmowała się aspektami operacyjnymi i prawnymi dotyczącymi technologii rozproszonych rejestrów (DLT/Blockchain), ze szczególnym uwzględnieniem tematyki walut wirtualnych oraz innych tokenów cyfrowych, ICO (Initial Coin Offerings), smart kontraktów, funkcjonowania giełd i kantorów wirtualnych, w tym giełd kryptowalut oraz ograniczeń i wyzwań dla rozwoju technologii DLT/Blockchain, w tym dla rozwoju walut wirtualnych.

"Chcielibyśmy rozpocząć dialog dotyczący rozwiązań związanych z technologią blockchain, w tym "walut" wirtualnych, ICO. Chcielibyśmy w ciągu najbliższych miesięcy wspólnie porozmawiać o wyzwaniach, przed którymi stoi branża, o percepcji obecnie funkcjonujących regulacji, o barierach oraz o tym, jak te bariery możemy usuwać lub ograniczać. Chcielibyśmy ustalić wspólny punkt widzenia" – powiedział Marek Chrzanowski, Przewodniczący KNF, który otworzył posiedzenie Grupy.

"W niektórych kwestiach się różnimy, ale w niektórych jesteśmy ze sobą bardzo blisko. Nie jesteśmy do nikogo uprzedzeni. Jesteśmy postrzegani przez pryzmat działań ostrzegawczych, które realizujemy w ramach kampanii dotyczących zagrożeń na rynku finansowym, natomiast chcę podkreślić, że co do zasady nie jesteśmy przeciwnikami technologii blockchain i nie chcemy

### Kluczowe odnośniki

- CLIP: <a href="http://clip.ipipan.waw.pl/">http://clip.ipipan.waw.pl/</a>
- CLARIN-PL: <a href="https://clarin-pl.eu">https://clarin-pl.eu</a>

- Słownik Gramatyczny Języka Polskiego: <a href="http://sgjp.pl/">http://sgjp.pl/</a>
- Słowosieć: <a href="http://plwordnet.pwr.wroc.pl/wordnet/">http://plwordnet.pwr.wroc.pl/wordnet/</a>

PolEval: <a href="http://poleval.pl">http://poleval.pl</a>

Dziękuję za uwagę!